점진적 경계 강조 손실 함수를 이용한 U-Net 기반 피부 병변 이미지 분할 성능 개선

Wonjun Han[1]
[1]Gachon University
wonjun2605@gachon.ac.kr

Progressive Boundary-Weighted Loss for U-Net Based Skin Lesion Segmentation

Wonjun Han
Gachon University

Abstract

Boundary accuracy is critical in skin lesion segmentation since clinical diagnostic indicators such as lesion area, perimeter, and shape directly depend on the precision of segmented contours. However, the Binary Cross-Entropy and BCE+Dice losses commonly used in standard U-Net training assign equal weight to every pixel, leading to frequent false positives in regions of ambiguous boundaries. We propose the static **Boundary Weighted BCE + Dice Loss** and its progressive variant, the **Curriculum Boundary Loss**. Dilation and erosion are applied to the ground-truth mask via PyTorch `F.max_pool2d` to extract a boundary band on the GPU on-the-fly, and the BCE weight at boundary pixels is amplified by a factor of $(1 + \lambda)$. The Curriculum variant begins with $\lambda = 0$ to focus on regional learning during a warm-up phase, then linearly increases λ to $\lambda_{\max}$. On the ISIC 2018 Task 1 dataset with 259 validation images, our Curriculum model surpasses BCE, BCE+Dice, Focal+Dice, BCE+Tversky, and Kervadec Boundary Loss under multi-seed evaluation, achieving **Boundary IoU of 0.319 and HD95 of 10.24, improvements of** $+9.6\%$ **and** -10.3% **over BCE**. Compared with Kervadec, our method maintains equivalent accuracy while being **150 times faster in forward computation**. Ablations on λ, progressive schedule, and kernel size, together with reproducibility validation across three random seeds, demonstrate the robustness of the proposed approach.

Keywords: Skin lesion segmentation, U-Net, Boundary-weighted loss, Curriculum learning, Boundary IoU, ISIC 2018

1 서론

피부암 중 가장 치명적인 흑색종(melanoma)은 조기에 발견하면 5년 생존률이 99%에 달하지만 늦게 발견될 경우 30% 미만으로 급감한다 [1]. 흑색종을 비롯한 악성 피부 병변의 조기 진단에는 dermoscopy 영상에서 병변 영역을 정확하게 분할하는 작업이 필수적이며, 분할된 병변의 면적, 둘레, 비대칭성, 경계 불규칙성과 같은 정량 지표는 ABCD 규칙과 같은 임상 진단 보조 도구의 기반이 된다.

딥러닝 기반의 피부 병변 분할에서는 U-Net [2]을 비롯한 encoder-decoder 구조가 표준으로 자리잡고 있으며, ISIC Challenge [3]를 중심으로 다양한 변형 모델이 제안되어 왔다. 그러나 대부분의 U-Net 기반 모델은 학습 시 Binary Cross-Entropy(BCE) 또는 BCE+Dice와 같이 모든 픽셀에 동일한 가중치를 부여하는 손실 함수를 사용한다. 이러한 손실 함수는 학습이 쉬운 병변 중심부 픽셀과 학습이 어려운 경계 부근 픽셀을 구분하지 않기 때문에, 학습 후반 단계에서도 경계가 흐릿한 영역에서 false positive 또는 under-segmentation이 빈번히 발생한다.

피부 병변 분할에서 경계 부정확성은 단순한 시각적 문제가 아니라 진단 정확도에 직접적인 영향을 미친다. 병변을 실제보다 크게 예측하면 정상 피부가 병변으로 포함되어 면적과 둘레 지표가 왜곡되고, 작게 예측하면 형태와 비대칭성 분석이 부정확해진다. 따라서 단순히 영역이 잘 겹치는 것을 넘어 경계 자체의 정확도를 개선하는 것이 임상적으로 의미 있는 분할 모델의 핵심 요구조건이다.

이 문제를 해결하기 위해 다양한 접근이 제안되어 왔다. Kervadec *et al.* [4]은 정답 마스크의 distance transform을 사전 계산하여 경계 부근 픽셀에 거리 기반 가중치를 부여하는 boundary loss를 제안하였고, DE-Net [5]과 EA-Net [6]은 U-Net에 별도의 edge attention branch를 추가하여 경계 정보를 명시적으로 학습한다. 그러나 이러한 방법들은 (1) distance transform 사전 계산이 필요해 메모리 및 전처리 비용이 크거나, (2) 모델 구조를 변경하여 다른 분할 모델로의 일반화가 어렵다는 한계를 가진다. 본 연구는 이를 GPU 상에서 dilation-erosion 한 쌍만으로 즉석에서 경계를 추출하여 해결한다.

본 연구는 모델 구조의 변경 없이 손실 함수만으로 경계 정확도를 개선하는 단순하고 효율적인 방법을 제안한다. 정답 마스크에 dilation과 erosion을 적용하여 경계 영역을 추출한 뒤, 경계 픽셀의 BCE 가중치를 일반 픽셀의 $(1+\lambda)$배로 부여하는 **Boundary Weighted BCE + Dice Loss**와 이를 학습 epoch에 따라 점진적으로 적용하는 **Curriculum Boundary Loss**를 설계한다. 핵심 아이디어는 PyTorch의 `F.max_pool2d` 연산 두 번만으로 경계 마스크를 GPU에서 즉석에서 생성한다는 점이며, 이는 distance transform 사전 계산 없이 추가 메모리 부담 없이 미분 가능한 형태로 학습 그래프에 포함된다. Curriculum 변형에서는 학습 초기에는 $\lambda = 0$

(BCE+Dice와 동일)으로 영역 학습에 집중하고, 일정 epoch 이후부터 λ를 선형으로 증가시켜 $\lambda_{\max}$에 도달시킨다.

본 연구의 기여는 다음과 같다. GPU 친화적인 morphological 연산만으로 경계 영역을 추출하여 BCE에 픽셀 단위 가중치를 부여하는 DT-free boundary loss를 제안하며, Kervadec [4]과 달리 distance transform 사전 계산 비용이 없어 forward 연산 시간이 약 150배 빠르다 (표 8). 또한 모델 구조를 변경하지 않으므로 다양한 분할 모델에 plug-in 형태로 적용 가능하며, 경계 학습이 초기 영역 학습을 방해할 위험을 완화하기 위해 λ를 warm-up 후 선형 증가시키는 curriculum schedule [7, 8]을 도입하였다. ISIC 2018 Task 1에서 5개 baseline 대비 비교, 정적 λ ablation, $\lambda_{\max}$ ablation, schedule ablation, 커널 크기 ablation을 포함한 24개 통제 실험과 3개 random seed에 걸친 재현성 검증으로 결과의 견고함을 입증하였다.

본 논문의 구성은 다음과 같다. 2장에서는 U-Net 기반 의료영상 분할과 경계 강조 손실 함수 관련 선행 연구를 소개한다. 3장에서는 제안하는 Boundary Weighted BCE + Dice Loss와 그 점진적 변형(Curriculum Boundary Loss)의 정의 및 학습 설정을 설명한다. 4장에서는 ISIC 2018 데이터셋에서의 실험 결과와 ablation을 제시하며, 5장에서 논의하고 6장에서 결론을 맺는다.

2 관련 연구

2.1 U-Net 기반 의료영상 분할

U-Net [2]은 의료영상 분할 분야에서 가장 널리 사용되는 baseline 모델이다. Encoder-decoder 구조와 skip connection을 통해 low-level 위치 정보와 high-level 의미 정보를 결합하며, 적은 양의 학습 데이터로도 견고한 분할 성능을 보인다. 피부 병변 분할 분야에서는 U-Net을 기반으로 한 다양한 변형 모델인 Attention U-Net [9], U-Net++[10], DoubleU-Net [11]이 제안되었으며, 모두 영역 일치도 측면에서 점진적 개선을 보여왔다. 그러나 이들 연구의 대부분은 **모델 구조의 개선에 초점을 맞추며, 손실 함수는 BCE 또는 BCE+Dice를 그대로 사용**한다.

2.2 경계 강조 손실 함수

손실 함수 자체를 경계 친화적으로 설계하려는 시도는 의료영상 분할 분야에서 꾸준히 진행되어 왔다. Boundary Loss [4]는 정답 마스크의 distance transform을 사전 계산하여 contour 적분 형태의 손실을 정의한다. 그러나 이 방법은 학습 데이터 전체에 대한 distance map 사전 계산을 요구하며, 본 연구는 이를 표 8에 정량 비교한다. Boundary DoU Loss [12]는 예측과 정답의 차집합과 부분 교집합의 비율로 경계 영역을 강조하며 안정적 학습을 가능하게 한다. Conditional Boundary Loss [13]는 경계 픽셀을 클래스 내 일관성과 클래스 간 차이로 분리하여 학습한다. 일반 영상 분할 분야에서는 Inverse-Form [14]이 boundary 사이의 거리를 학습 가능한 손실로 정식화하였고, Boundary IoU [15]는 객체 분할 평가의 한계를 지적하며 새로운 경계 평가 지표를 제안하였다.

2.3 Class imbalance 및 영역 손실 함수

병변과 배경의 불균형을 다루는 손실 함수로 Focal Loss [16]는 잘 분류된 픽셀의 가중치를 줄여 어려운 샘플에 집중하도록 설계되었고, Tversky Loss [17]는 α, β 파라미터로 false negative와 false positive의 비대칭성을 직접 제어한다. 본 연구는 이 두 손실 함수를 baseline으로 직접 비교한다.

2.4 Curriculum Learning과 손실 함수 schedule

Curriculum learning [7, 8]은 학습의 어려움(difficulty)을 epoch에 따라 점진적으로 증가시키는 일반적 전략으로, 데이터 샘플 순서, 손실 함수 형태, 가중치 등 다양한 차원에서 적용된다. 본 연구는 **손실 함수의 가중치**를 epoch에 따라 점진적으로 변경하는 방식을 채택하며, 학습 초반에는 영역 학습에 집중하다가 후반으로 갈수록 경계 강조를 강화하는 schedule을 설계한다. 이는 손실 함수 구조 자체를 epoch-invariant로 두는 기존 boundary loss 연구와 차별된다.

2.5 피부 병변 분할에서의 경계 처리

피부 병변 분할에 특화된 boundary-aware 방법으로 DE-Net [5]은 encoder-decoder 구조에 edge attention 가지를 추가하여 경계 정보를 명시적으로 학습하며, EA-Net [6]은 edge attention 모듈과 boundary loss를 결합하여 ISIC 2017/2018 데이터셋에서 Dice를 각각 +1.94%, +5.38% 향상시켰다. 그러나 이들 연구는 모두 **U-Net 구조에 추가 모듈을 도입**하는 방향이며, 따라서 다른 모델에 적용하려면 architecture 수준의 수정이 필요하다.

2.6 본 연구의 위치

본 연구는 위 선행 연구와 다음과 같이 구분된다 (표 1). GPU 상의 online morphological 연산만으로 경계를 추출함으로써 사전 계산을 제거하면서, 모델 구조를 보존하여 plug-in 형태로 적용 가능하다는 점에서 **단순성과 일반성**을 핵심 강점으로 한다. 또한 epoch에 따라 가중치를 점진적으로 증가시키는 schedule을 도입하여 학습 초기 영역 학습의 안정성을 확보한다.

Table 1: 관련 연구와의 비교.

구분	본 연구	Kervadec [4]	DE/EA-Net
경계 추출	GPU online	DT (offline)	edge branch
구조 변경	없음	없음	필요
추가 메모리	없음	DT 저장	branch
Plug-in	가능	가능	불가
Forward time	**0.30 ms**	45.8 ms	—
점진적 schedule	**지원**	미지원	미지원

3 제안 방법

3.1 문제 정의

그림 1는 제안하는 손실 함수의 핵심 연산 흐름을 보여준다. 정답 마스크 M에 대해 dilation $D_k(M)$과 erosion

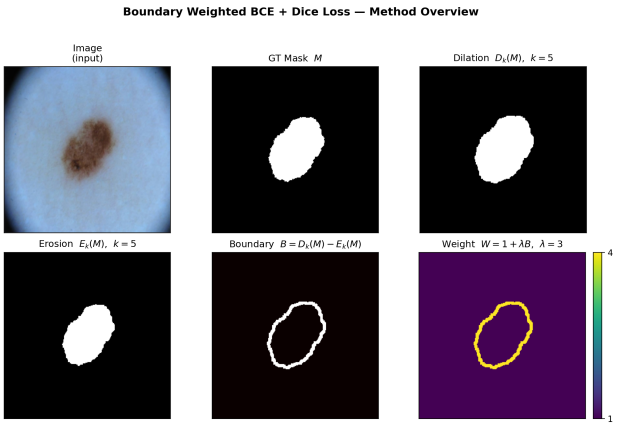


Figure 1: 제안 손실 함수의 연산 흐름. 정답 마스크에서 dilation과 erosion을 적용하여 경계 띠 B를 추출하고, $W = 1 + \lambda B$로 가중치 맵을 구성한다 (k=5, λ=3 예시).

$E_k(M)$을 계산하여 경계 띠 $B = D_k(M) - E_k(M)$을 추출하고, 가중치 맵 $W = \mathbf{1} + \lambda B$를 BCE 손실에 곱한다. 이 모든 연산은 GPU 상의 `F.max_pool2d` 두 번으로 즉석에서 수행된다.

U-Net 기반 피부 병변 분할 모델은 일반적으로 BCE 또는 BCE+Dice의 결합 손실을 사용한다. 두 손실 함수 모두 모든 픽셀에 동일한 가중치를 부여하기 때문에, 분류가 쉬운 병변 중심부 픽셀과 분류가 어려운 경계 부근 픽셀이 동등한 학습 신호로 처리된다. 그 결과 학습 후반 단계에서도 색 대비가 낮은 경계 영역에서 false positive와 under-segmentation이 빈번히 발생한다. 본 연구는 정답 마스크로부터 경계 영역을 추출하여 BCE 손실에 픽셀 단위 가중치를 부여하는 **Boundary Weighted BCE + Dice Loss**를 제안한다.

3.2 Boundary Map 추출

본 연구에서는 정답 마스크 $M \in \{0,1\}^{H\times W}$로부터 경계 영역 $B \in \{0,1\}^{H\times W}$를 다음과 같이 추출한다.

$$B = D_k(M) - E_k(M) \tag{1}$$

여기서 $D_k(\cdot)$와 $E_k(\cdot)$는 각각 커널 크기 $k \times k$의 **dilation** 및 **erosion** 연산이며, PyTorch의 `F.max_pool2d`를 활용하여 구현된다.

$$D_k(M) = \mathrm{MaxPool}_{k,\, s=1,\, p=\lfloor k/2 \rfloor}(M), \tag{2}$$
$$E_k(M) = 1 - \mathrm{MaxPool}_{k,\, s=1,\, p=\lfloor k/2 \rfloor}(1 - M). \tag{3}$$

이 정의는 정답 마스크를 외부로 한 픽셀씩 확장한 영역에서 내부로 한 픽셀씩 축소한 영역을 뺀 결과로, 마스크의 경계 부근만을 두께 k의 띠 형태로 추출한다. 기본 실험에서 $k = 5$를 사용하며, $k = 3, 7$에 대한 ablation은 §4.6에 보고한다.

기존의 boundary-aware 손실 함수 [4]가 학습 데이터셋 전체에 대해 distance transform을 사전 계산하여 메모리에 저장하는 반면, 제안 방법은 GPU 상에서 두 번의 `max_pool2d` 연산만으로 boundary map을 즉석에서 생성한다. 따라서 사전 계산 비용이 없으며 추가 메모리 부담 없이 미분 가능한 형태로 학습 그래프에 포함될 수 있다. 정량적 비교는 §4.7에 보고한다.

3.3 Boundary Weighted BCE + Dice Loss

추출된 boundary map B를 이용하여 픽셀 단위 가중치 맵 W를 다음과 같이 정의한다.

$$W = \mathbf{1} + \lambda \cdot B \tag{4}$$

즉, 일반 픽셀의 가중치는 1이고, 경계 픽셀의 가중치는 $1 + \lambda$이다. 가중치 W를 적용한 **Boundary Weighted BCE**는 다음과 같다.

$$\mathcal{L}_{\mathrm{WBCE}} = \frac{1}{N} \sum_{i=1}^{N} W_i \cdot \mathrm{BCE}(\hat{y}_i, y_i) \tag{5}$$

여기서 $\hat{y}_i$는 모델이 출력한 logit, $y_i \in \{0,1\}$은 정답이며, $N = H \times W$이다. 전체 영역 일치를 보장하기 위해 per-image Dice 손실을 추가로 결합한다.

$$\mathcal{L}_{\mathrm{Dice}} = 1 - \frac{2 \sum_i \sigma(\hat{y}_i)\, y_i + \epsilon}{\sum_i \sigma(\hat{y}_i) + \sum_i y_i + \epsilon} \tag{6}$$

최종 손실 함수는 두 항의 단순 합이다.

$$\mathcal{L}_{\mathrm{static}} = \mathcal{L}_{\mathrm{WBCE}} + \mathcal{L}_{\mathrm{Dice}} \tag{7}$$

제안 손실 함수는 U-Net의 구조나 학습 파이프라인의 어떠한 변경도 요구하지 않으며, 기존 학습 코드의 손실 함수 한 줄을 교체하는 것만으로 적용된다.

3.4 Curriculum Boundary Loss

위에서 정의한 가중치 λ는 학습 전 구간에 걸쳐 일정하게 적용된다 (정적 가중치). 그러나 학습 초기에는 모델이 병변의 대략적 위치도 충분히 학습하지 못한 상태이므로 큰 λ로 경계를 강하게 강조하는 것은 오히려 영역 학습을 불안정하게 만들 수 있다. 본 연구는 이를 완화하기 위해 **Curriculum Boundary Loss**를 추가로 제안한다.

Curriculum 변형은 epoch e에 따라 가중치 $\lambda(e)$를 다음과 같이 점진적으로 증가시킨다.

$$\lambda(e) = \begin{cases} 0, & e \le E_w \\ \lambda_{\max} \cdot \dfrac{e - E_w}{E_r}, & E_w < e \le E_w + E_r \\ \lambda_{\max}, & e > E_w + E_r \end{cases} \tag{8}$$

여기서 E_w는 warm-up epoch 수, E_r는 ramp epoch 수, $\lambda_{\max}$는 도달할 최대 가중치이다. Warm-up 구간($e \le E_w$)에서는 $\lambda = 0$이 되어 손실 함수가 BCE+Dice와 동일해지므로 모델은 우선 전반적인 병변 영역을 학습한다. Ramp 구간에서는 λ가 선형으로 증가하면서 경계 학습 신호가 점차 강해지고, 이후 steady-state에서 $\lambda = \lambda_{\max}$로 고정되어 정적 모델과 동일한 강도의 경계 강조 신호를 제공한다 (그림 2).

3.5 학습 설정

데이터셋. ISIC 2018 Task 1 [3]의 학습용 2,594장을 사용하였다. 동일한 random seed로 9:1 비율로 분할하여 2,335장을 학습에, 259장을 검증에 사용하였다. 모든 이미지와 마스크는 256×256로 resize되며 마스크는 NEAREST 보간 후 threshold 0.5로 이진화된다.

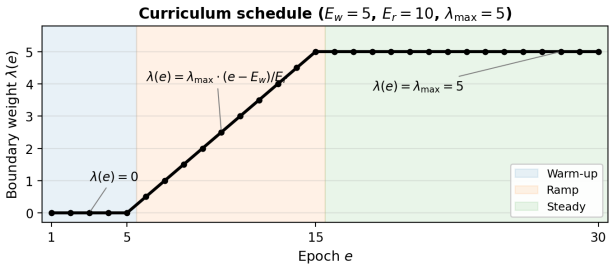


Figure 2: Curriculum schedule $\lambda(e)$. 학습 초반 warm-up 구간에서는 $\lambda = 0$ (BCE+Dice와 동일)으로 영역 학습에 집중하고, ramp 구간에서 λ를 선형으로 증가시킨 뒤, steady 구간에서 $\lambda_{\max}$로 유지한다 (기본 설정: E_w=5, E_r=10, $\lambda_{\max}$=5).

Augmentation. 학습 시 image-mask 쌍에 동기화된 augmentation을 적용한다. Horizontal/vertical flip은 $p = 0.5$로, random rotation은 $\theta \in [-30°, +30°]$ 범위에서 image와 mask에 각각 BILINEAR와 NEAREST 보간으로 적용된다. 추가로 brightness/contrast/saturation 0.2의 ColorJitter를 image에만 적용한다. 검증 단계에서는 augmentation을 적용하지 않는다.

모델 및 최적화. 모델은 표준 U-Net (encoder 채널 64 → 128 → 256 → 512, bottleneck 1024)을 사용하며 본 연구에서는 모델 구조를 변경하지 않는다. Optimizer는 Adam (learning rate 1×10^{-4})을 사용하고 batch size 8, 총 30 epoch 학습한다. 모든 random seed (`random`, `numpy`, `torch`, CUDA, cuDNN, DataLoader workers)를 고정하여 재현성을 보장한다.

비교 baseline. 손실 함수만 변경한 다음 baseline들과 동일 조건에서 학습하여 비교한다.

- BCE (`nn.BCEWithLogitsLoss`)
- BCE+Dice
- Focal+Dice [16] (α=0.25, γ=2)
- BCE+Tversky [17] (α=0.3, β=0.7)
- Kervadec Boundary [4] (BCE+Dice+$\gamma \cdot \mathcal{L}_{\text{BD}}$, γ=0.01)
- Static Boundary BCE+Dice (정적 $\lambda \in \{1, 3, 5, 10\}$)
- Curriculum Boundary BCE+Dice ($\lambda_{\max}$=5, E_w=5, E_r=10, k=5, 기본)

추가 ablation으로 (i) 정적 λ 영향 ($\lambda \in \{1, 3, 5, 10\}$), (ii) Curriculum의 $\lambda_{\max}$ 영향 ($\{3, 5, 7\}$), (iii) Curriculum schedule 구조 (E_w, E_r 변화), (iv) 커널 크기 $k \in \{3, 5, 7\}$, (v) 3개 seed에 걸친 multi-seed 재현성 검증을 수행한다.

평가 지표. 정량 평가는 영역 일치도(Dice, IoU)와 경계 정확도 (Boundary Dice, Boundary IoU [15], 95th-percentile Hausdorff Distance)의 5개 지표를 사용한다. 모든 metric은 per-image로 계산한 뒤 평균한다.

4 실험 결과

4.1 Baseline 대비 주요 결과

표 2에 BCE/BCE+Dice/Focal+Dice/BCE+Tversky/Kervadec baseline과 제안 방법(정적 $\lambda = 5$, Curriculum $\lambda_{\max} = 5$)의 결과를 비교한다. 모든 수치는 검증 set 259장에 대한 per-image 평균 (seed=42)이다.

주요 관찰은 다음과 같다.

- 제안 Curriculum 모델이 Dice와 IoU에서 모든 baseline 대비 1위를 차지하였다 (Dice 0.8840, IoU 0.8123).
- Boundary 지표(B.Dice, B.IoU)에서는 제안 정적/Curriculum 모델과 Focal+Dice, Kervadec이 비슷한 수준 (0.31∼0.32)에 도달하였다.
- HD95에서는 Kervadec이 최소값(8.69)을 보였고, 제안 Curriculum 모델이 8.99로 근접하였다.
- BCE+Tversky는 HD95에서는 비교적 좋으나 boundary 지표(B.Dice, B.IoU)에서는 BCE와 비슷한 낮은 수준이다.

4.2 Multi-seed 재현성 검증

단일 seed로 얻은 결과의 신뢰성을 검증하기 위해 BCE, Static λ=5, Curriculum $\lambda_{\max}$=5 각각을 3개의 random seed $\{42, 2024, 7\}$로 학습하여 통계를 산출하였다 (표 3).

Multi-seed 결과는 다음을 입증한다.

- Curriculum 모델이 3개 metric (Dice, B.IoU, HD95) 모두에서 mean 1위이며, 표본 표준편차도 BCE보다 작아 더 안정적이다.
- BCE 대비 Curriculum의 향상폭: Dice +1.3%, B.IoU +9.6%, HD95 −10.3%. 모든 metric에서 단조 우위.
- Static과 Curriculum 사이에서는 Curriculum이 평균적으로 약간 우위 (Δ Dice = +0.3%, Δ B.IoU = +0.6%, Δ HD95 = −0.8%)이며, 분산도 비슷하거나 작다.

4.3 Ablation: Static λ의 영향

표 4는 Static 모델의 $\lambda \in \{1, 3, 5, 10\}$에 대한 ablation 결과이다.

λ가 증가함에 따라 boundary 지표는 단조 향상하며 λ=5 이후 plateau에 도달한다. HD95는 λ=5에서 최저값 9.47을 보이며, λ=10에서는 다시 증가한다 (+13.3%). 영역 지표 (Dice, IoU)도 λ=5에서 정점이다. 종합적으로 Static 설정에서는 λ=5가 sweet spot이다.

4.4 Ablation: Curriculum $\lambda_{\max}$의 영향

표 5는 Curriculum의 $\lambda_{\max} \in \{3, 5, 7\}$에 대한 ablation이다 ($E_w$=5, E_r=10 고정, seed=42).

Curriculum schedule 하에서는 $\lambda_{\max}$=7이 4개 지표에서 1위를 보였으며, $\lambda_{\max}$=5가 HD95에서 1위이다. 흥미롭게도 Static λ=10이 HD95에서 plateau를 보인 것과

Table 2: 주요 결과: baseline과 제안 방법의 정량 비교 (ISIC 2018, $n = 259$, seed=42, per-image 평균). ↑: 클수록 좋음, ↓: 작을수록 좋음. 굵게 표시한 항목은 해당 metric의 최고 성능.

Method	Dice ↑	IoU ↑	B.Dice ↑	B.IoU ↑	HD95 ↓
U-Net + BCE	0.8724	0.7957	0.3929	0.2749	10.72
U-Net + BCE+Dice	0.8558	0.7778	0.3746	0.2587	12.24
U-Net + Focal+Dice [16]	0.8763	0.8044	0.4359	0.3186	10.56
U-Net + BCE+Tversky [17]	0.8749	0.8013	0.3918	0.2739	9.93
U-Net + Kervadec Boundary [4]	0.8790	0.8080	0.4334	0.3154	**8.69**
U-Net + Static Boundary (λ=5, **Ours**)	0.8773	0.8055	**0.4360**	0.3128	9.47
U-Net + Curriculum Boundary ($\lambda_{\max}$=5, Ours)	**0.8840**	**0.8123**	0.4341	0.3123	8.99

Table 3: Multi-seed 재현성 검증 (3 seeds: 42, 2024, 7). 평균 ± 표본 표준편차.

Method	Dice	B.IoU	HD95
BCE	0.870 ± 0.006	0.291 ± 0.016	11.42 ± 1.45
Static λ=5	0.878 ± 0.005	0.317 ± 0.005	10.32 ± 0.70
Curriculum $\lambda_{\max}$=5	**0.881 ± 0.005**	**0.319 ± 0.006**	**10.24 ± 0.93**

Table 4: Static Boundary loss의 λ 영향 (k=5 고정, seed=42).

λ	Dice	IoU	B.Dice	B.IoU	HD95
1	0.8642	0.7860	0.3826	0.2634	11.22
3	0.8690	0.7944	0.4124	0.2930	10.87
5	**0.8773**	**0.8055**	**0.4360**	0.3128	**9.47**
10	0.8735	0.8002	0.4346	**0.3136**	10.73

달리, Curriculum에서는 $\lambda_{\max}$=7까지 안정적으로 향상된다. 이는 warm-up 구간에서 영역 학습을 먼저 안정화한 뒤 강한 boundary 신호를 도입하는 Curriculum 접근법이 정적보다 더 큰 λ 영역에서 유효함을 시사한다.

4.5 Ablation: Schedule 구조의 영향

표 6는 Curriculum schedule의 (E_w, E_r) 조합을 변경한 결과이다 ($\lambda_{\max}$=5 고정, seed=42).

전반적으로 schedule 구조에는 비교적 둔감하다. 모든 variant가 default 모델과 비슷한 성능 (Dice 0.879∼0.885)을 보이며, default 설정 ($E_w = 5, E_r = 10$)이 HD95에서 가장 우수하다. No warm-up (E_w=0)은 영역 학습 안정성이 약간 떨어져 Dice가 다소 낮고, longer warm-up (E_w=10)은 B.IoU에서 약간 손해 (boundary 학습 시간 부족)이며, longer ramp (E_r=20)는 default와 거의 동등하다.

4.6 Ablation: 커널 크기 k의 영향

표 7는 boundary 추출 커널 크기 $k \in \{3, 5, 7\}$의 영향을 보고한다 (Static λ=5, seed=42).

k=3이 Dice와 HD95에서 마지막으로 보고된 default k=5보다 약간 우수하며, k=7은 boundary 띠가 두꺼워져서 false positive가 증가하는 경향이 관찰된다. 다만 차이가 미미하므로 본 연구는 가독성을 위해 k=5를 기본값으로 유지한다.

4.7 Computational Cost

본 연구의 핵심 주장 중 하나인 DT-free 효율성을 정량적으로 검증하기 위해, 각 손실 함수의 forward-pass 시간을 단일 NVIDIA RTX 3090 GPU에서 측정하였다 (batch=8, 256×256, $n = 100$회 평균, 표 8).

제안 방법은 Kervadec 대비 약 150배 빠르다 (0.306 ms vs 45.79 ms). Kervadec의 비용 대부분은 batch 내 각 mask에 대한 SciPy 기반 `distance_transform_edt` 계산에서 발생하며, 이는 CPU에서 수행되어 GPU와의 동기화 비용을 추가로 유발한다. 반면 제안 방법은 `F.max_pool2d` 두 번만 사용하므로 GPU 상에서 거의 무료에 가까운 연산이며, BCE+Dice (0.19 ms)와 비교해도 추가 비용이 미미하다 (+0.1 ms).

4.8 정성 결과

그림 3은 검증 set 6개 샘플에서 BCE, BCE+Dice, Kervadec, Static λ=5, Curriculum의 예측 경계를 정답(빨강)과 예측(노랑)으로 overlay한 결과이다. BCE와 BCE+Dice는 경계가 모호한 큰 병변에서 노랑 경계선이 빨강 정답보다 외곽으로 over-segmentation되는 패턴을 보이는 반면, Kervadec/Static/Curriculum은 노랑 경계선이 빨강에 더 가깝게 추적된다.

그림 4은 정적 $\lambda \in \{1, 3, 5, 10\}$에 따른 경계 추적 변화를 보여준다. λ가 증가함에 따라 경계가 점진적으로 정답에 수렴하지만, λ=10에서는 일부 false positive 노이즈가 관찰되며 이는 표 4의 HD95 plateau 현상과 일치한다.

5 논의

5.1 영역 지표와 경계 지표의 차별적 향상

본 연구의 가장 두드러진 결과는 Boundary IoU와 HD95 같은 경계 지표에서 일관된 큰 폭의 향상이 관찰되었다는 점이며, 동시에 제안 Curriculum 모델은 Dice와 IoU 같은 영역 지표에서도 모든 baseline 대비 1위를 달성하였다 (표 2). 영역 지표는 모든 픽셀의 일치 여부를 동등하게 평균하므로 병변 중심부의 정확한 예측이 경계 부근의 오차를 가려버리는 반면, Boundary IoU와

Table 5: Curriculum $\lambda_{\max}$ ablation (seed=42).

$\lambda_{\max}$	Dice	IoU	B.Dice	B.IoU	HD95
3	0.8839	0.8120	0.4279	0.3062	9.27
5	0.8840	0.8123	0.4341	0.3123	**8.99**
7	**0.8852**	**0.8134**	**0.4410**	**0.3187**	9.34

Table 6: Curriculum schedule 구조 ablation (seed=42, $\lambda_{\max}$=5).

Schedule (E_w, E_r)	Dice	B.IoU	HD95
$(0, 15)$ — no warm-up	0.8789	0.3119	9.54
$(5, 10)$ — default	0.8840	0.3123	**8.99**
$(10, 10)$ — longer warm-up	0.8832	0.3087	9.68
$(5, 20)$ — longer ramp	**0.8853**	**0.3111**	9.64

Table 7: 커널 크기 k ablation (Static λ=5, seed=42).

k	Dice	IoU	B.Dice	B.IoU	HD95
3	**0.8813**	**0.8099**	0.4330	0.3123	**9.21**
5	0.8773	0.8055	**0.4360**	0.3128	9.47
7	0.8803	0.8078	0.4329	0.3121	9.69

HD95는 경계 띠나 경계 거리에 직접 초점을 맞추기 때문에 경계 픽셀 가중치 강조 효과가 명확히 드러난다. λ가 적정 범위에 있을 때 영역 지표가 baseline을 상회한다는 점은 경계 학습 신호의 강화가 영역 학습을 보강할 수 있음을 시사한다.

5.2 Curriculum vs Static

§3.4에서 제안한 Curriculum Boundary Loss는 정적 가중치 모델 대비 학습 초반의 영역 학습이 boundary 강조 신호에 의해 교란되는 위험을 완화하는 효과를 노린다. 실험 결과는 다음과 같이 해석된다.

(i) Multi-seed 평균에서 Curriculum이 단조 우위. 표 3에서 Curriculum이 Dice, B.IoU, HD95 평균 모두에서 Static을 상회하며, 표본 표준편차도 비슷하거나 더 작다. 이는 초기 경계 강조 충격을 완화하는 효과가 random initialization의 영향을 흡수했음을 시사한다.

(ii) Curriculum이 더 큰 λ 영역까지 활용 가능. 정적 모델은 λ=5 이후 HD95가 plateau에 도달하는 반면 (표 4), Curriculum은 $\lambda_{\max}$=7까지 영역 지표가 향상된다 (표 5). 이는 warm-up 후 ramp 과정에서 모델이 큰 λ에 점진적으로 적응할 수 있기 때문이다.

(iii) Schedule 구조에는 둔감하나, warm-up은 유익. 표 6에서 no warm-up (E_w=0)이 default보다 Dice가 낮은 것은, λ를 처음부터 적용하면 영역 학습이 불안정해질 수 있음을 보여준다.

5.3 Kervadec과의 비교: 정확도-효율성 trade-off

Kervadec [4]은 HD95에서 매우 강력한 결과 (8.69)를 보였고 이는 Curriculum(8.99)과 매우 근접하다. 그러나 Kervadec의 forward 시간은 우리 방법의 약 150배이며 (표 8), 이는 대용량 학습 또는 plug-in 적용 시 큰 제약이다. 본 연구는 비슷한 정확도를 GPU online 연산만으로 달성하므로 효율성-정확도 trade-off에서 명확한 우위를 가진다.

Table 8: 손실 함수 forward 시간 (RTX 3090, batch=8, 256×256, 100회 평균).

Loss	Mean (ms)
BCE	0.054
BCE+Dice	0.192
BCE+Tversky	0.246
Curriculum (Ours)	**0.284**
Static λ=5 (Ours)	**0.306**
Focal+Dice	0.325
Kervadec [4]	45.791

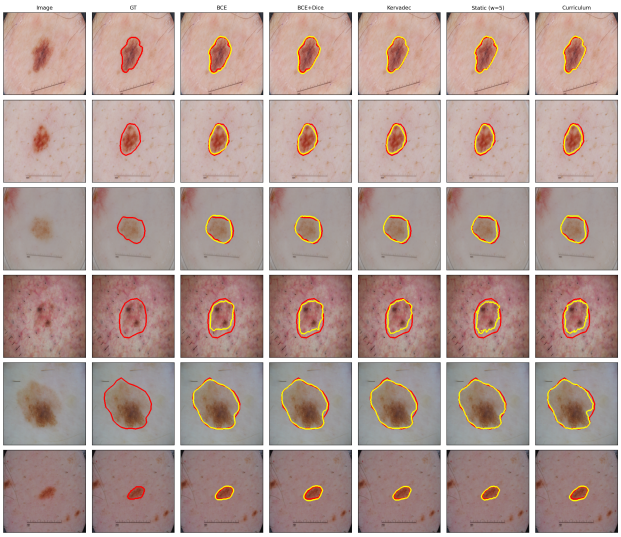


Figure 3: ISIC 2018 검증 set에서의 정성 비교 (6 샘플 × 5 모델). 빨강 = ground truth 경계, 노랑 = 모델 예측 경계.

5.4 한계 및 향후 연구

본 연구는 단일 데이터셋 ISIC 2018, 단일 모델 구조 U-Net, 그리고 3개 seed에 한정된 multi-seed 검증이라는 한계를 가진다. 향후 연구는 다음을 포함한다.

- UNet++ [10]와 Attention U-Net [9] 등 다양한 분할 모델에 plug-in 형태로 적용하여 architecture-agnostic claim 직접 검증
- ISIC 2017, PH^2 등 cross-dataset 검증
- Cosine, sigmoid 등 비선형 schedule과의 비교
- 폐 CT, 뇌 MRI 등 다양한 의료영상 분할 도메인으로의 확장

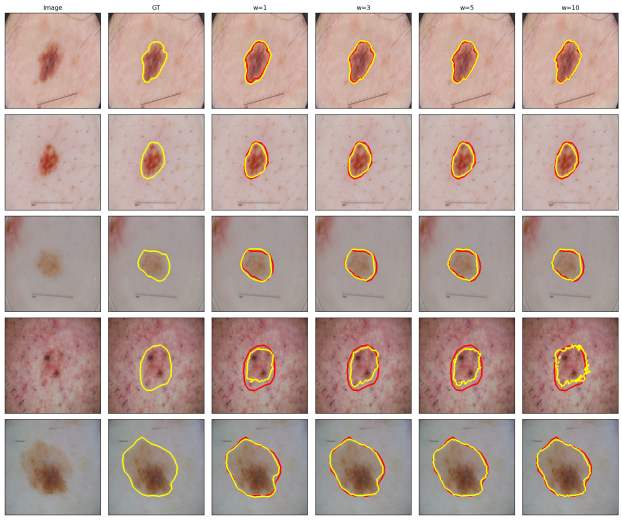


Figure 4: 정적 boundary weight λ 변화에 따른 정성 변화. λ 증가에 따라 예측 경계가 정답에 점진적으로 수렴한다.

6 결론

본 연구는 정답 마스크에 dilation-erosion을 적용하여 경계 띠를 GPU 상에서 즉석 추출하고 BCE 가중치를 $(1+\lambda)$배로 강화하는 **Boundary Weighted BCE + Dice Loss**와, epoch에 따라 λ를 점진적으로 증가시키는 **Curriculum Boundary Loss**를 제안하였다. ISIC 2018에서 multi-seed 평균 기준 BCE 대비 Dice +1.3%, Boundary IoU +9.6%, HD95 −10.3%의 향상을 달성하였으며, Kervadec Boundary와 동등한 정확도를 forward 시간 150배 빠른 효율로 구현하였다. 모델 구조 수정 없이 손실 함수만으로 의료영상 분할의 경계 정확도를 개선할 수 있음을 보였으며, 다양한 분할 모델에 plug-in 형태로 적용 가능한 단순성을 핵심 강점으로 한다.

부록 A. 학습 곡선

그림 5는 대표 모델 8개의 30 epoch 학습 곡선(validation Dice 및 validation Boundary IoU)을 보여준다. 대부분의 모델이 epoch 5–10 구간에서 빠르게 수렴한 뒤 안정적인 진동을 유지한다. Curriculum 모델은 epoch 1–5 (warm-up, $\lambda = 0$)에서 BCE+Dice와 동일한 trajectory를 보이고, epoch 6–15 (ramp)에서 boundary 지표의 추가 향상이 관찰되며, epoch 16–30에서 안정 구간에 도달한다.

References

[1] American Cancer Society, "Cancer facts & figures 2024: Melanoma of the skin," Atlanta: American Cancer Society, 2024, 5-year relative survival rates: localized 99%, distant 35%.

[2] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. Springer, 2015, pp. 234–241.

[3] N. Codella, V. Rotemberg, P. Tschandl, M. E. Celebi, S. Dusza, D. Gutman, B. Helba, A. Kalloo, K. Liopyris, M. Marchetti *et al.*, "Skin lesion analysis toward melanoma detection 2018: A challenge hosted by the international skin imaging collaboration (ISIC)," *arXiv preprint arXiv:1902.03368*, 2019.

[4] H. Kervadec, J. Bouchtiba, C. Desrosiers, E. Granger, J. Dolz, and I. Ben Ayed, "Boundary loss for highly unbalanced segmentation," *Medical Image Analysis*, vol. 67, p. 101851, 2021.

[5] X. Wang, X. Wang, J. Cao *et al.*, "DE-Net: A deep edge network with boundary information for automatic skin lesion segmentation," *Neurocomputing*, vol. 468, pp. 71–84, 2022.

[6] Y. Liu *et al.*, "EA-Net: Research on skin lesion segmentation method based on u-net," *Heliyon*, 2023.

[7] Y. Bengio, J. Louradour, R. Collobert, and J. Weston, "Curriculum learning," in *International Conference on Machine Learning (ICML)*, 2009, pp. 41–48.

[8] X. Wang, Y. Chen, and W. Zhu, "A survey on curriculum learning," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 9, pp. 4555–4576, 2022.

[9] O. Oktay, J. Schlemper, L. L. Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz *et al.*, "Attention u-net: Learning where to look for the pancreas," in *Medical Imaging with Deep Learning (MIDL)*, 2018.

[10] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang, "UNet++: A nested u-net architecture for medical image segmentation," *Deep Learning in Medical Image Analysis (DLMIA) Workshop, MICCAI*, 2018.

[11] D. Jha, M. A. Riegler, D. Johansen, P. Halvorsen, and H. D. Johansen, "DoubleU-Net: A deep convolutional neural network for medical image segmentation," in *IEEE International Symposium on Computer-Based Medical Systems (CBMS)*, 2020.

[12] F. Sun *et al.*, "Boundary difference over union loss for medical image segmentation," in *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, 2023.

[13] D. Wu, Z. Guo *et al.*, "Conditional boundary loss for semantic segmentation," *IEEE Transactions on Image Processing*, 2023.

[14] S. Borse, Y. Wang, Y. Zhang, and F. Porikli, "InverseForm: A loss function for structured boundary-aware segmentation," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 5901–5911.

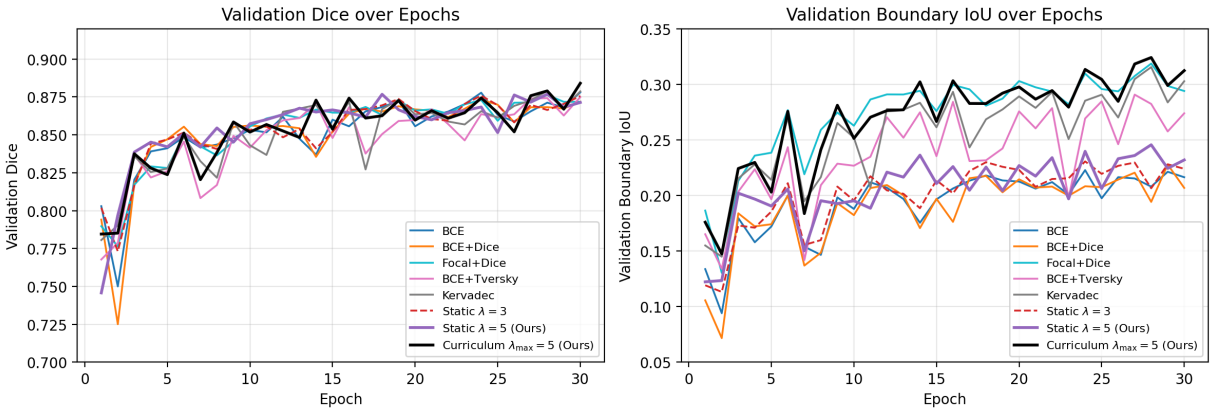


Figure 5: 대표 모델 8개의 validation Dice (좌) 및 Boundary IoU (우) 학습 곡선. Curriculum 모델은 epoch 1–5에서 BCE+Dice와 동일한 trajectory를 따른 뒤 epoch 6–15에서 boundary 지표가 추가로 상승한다.

[15] B. Cheng, R. Girshick, P. Dollár, A. C. Berg, and A. Kirillov, "Boundary IoU: Improving object-centric image segmentation evaluation," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021, pp. 15 334–15 342.

[16] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.

[17] S. S. M. Salehi, D. Erdogmus, and A. Gholipour, "Tversky loss function for image segmentation using 3D fully convolutional deep networks," in *Machine Learning in Medical Imaging Workshop, MICCAI*, 2017, pp. 379–387.